

Гипотеза	Вывод системы	Результат
Более высокий уровень образования связан с более высокой заработной платой	Суть исследования H0: Средняя заработная плата не зависит от уровня образования H1: Средняя заработная плата зависит от уровня образования Обработка данных Данные были очищены путем удаления 141 выброса в переменной lnwage, что составляет 8,58% - 11,59% от общего количества данных. После очистки данных были проанализированы на нормальность распределения. Статистическая проверка Был выбран критерий Крускала-Уоллиса (Kruskal), поскольку данные имеют нормальное распределение, но количество наблюдений в каждой группе различно. Этот критерий позволяет сравнивать средние значения в нескольких группах. Результат p-val = 6,44e-52, что значительно меньше порога значимости 0,05. Это означает, что существует статистически значимая разница в средней заработной плате между группами с разным уровнем образования. Заключение Отвергаем нулевую гипотезу H0, поскольку существует статистически значимая разница в средней заработной плате между группами с разным уровнем образования. Вывод Более высокий уровень образования связан с более высокой заработной платой. Согласно результатам линейной регрессии, каждый дополнительный уровень образования увеличивает заработную плату на 0,091 (для первого уровня), 0,055 (для второго уровня) и 0,374 (для третьего уровня) единиц. Это подтверждает гипотезу, что более высокий уровень образования связан с более высокой заработной платой.	согласуется
Заработная плата увеличивается с возрастом (как прокси опыта)	Суть исследования H0: Заработная плата не зависит от возраста H1: Заработная плата зависит от возраста Обработка данных Данные были предварительно обработаны, удалено 141 выбросов по таргету 'lnwage' (8.58 - 11.59) и 0 выбросов по группировке 'age' (9.01 - 76.50). Статистическая проверка Была выбрана линейная регрессия, так как обе переменные ('lnwage' и 'age') являются количественными. Коэффициент корреляции Пирсона между 'lnwage' и 'age' составляет -0.08971331631419023, а коэффициент корреляции Спирмена - -0.09397155877238113. Результат p-value для коэффициента 'age' в линейной регрессии составляет примерно 0.000, что меньше порога значимости 0.05. Заключение Отвергаем H0, так как существует статистически значимая связь между заработной платой и возрастом. Вывод Заработная плата уменьшается с возрастом, что противоречит гипотезе, что заработная плата увеличивается с возрастом.	не согласуется
Разбей возраст на интервалы в 10 лет. От 20 до 60. Заработная плата увеличивается с возрастом (как прокси опыта)	Суть исследования H0: Средняя заработная плата не зависит от возраста H1: Средняя заработная плата зависит от возраста Обработка данных Данные были очищены путем удаления 141 выброса для переменной lnwage, что составляет 8,58 - 11,59. Данные были разделены на группы по возрасту: 20-30, 30-40, 40-50, 50-60. Статистическая проверка Был выбран критерий KRUSKAL, поскольку данные имеют нормальное распределение, но тест Левена показал отрицательный результат, указывающий на отсутствие гомогенности дисперсий. Это означает, что мы не можем использовать параметрический метод. Результат p-val KRUSKAL-теста составляет примерно 2,07e-14, что значительно меньше порога значимости 0,05.	Согласуется

	Заключение Мы отвергаем нулевую гипотезу H_0, поскольку $p\text{-val}$ KRUSKAL-теста меньше порога значимости. Это означает, что существует статистически значимая разница в средней заработной плате между разными возрастными группами. Вывод Согласно результатам линейной регрессии, можно сделать вывод, что заработная плата увеличивается с возрастом, но не линейно. Группа 30-40 лет имеет более высокую заработную плату, чем группа 20-30 лет, но группы 40-50 и 50-60 лет имеют более низкую заработную плату, чем группа 30-40 лет. Это может указывать на то, что опыт и возраст имеют положительное влияние на заработную плату, но только до определенного возраста.	
Мужчины зарабатывают больше женщин	Суть исследования H_0: Средняя зарплата мужчин и женщин одинакова H_1: Средняя зарплата мужчин и женщин различается Обработка данных Данные были обработаны путем удаления 141 выброса для переменной 'lnwage', что составляет 8.58 - 11.59. Тип переменной 'male' был изменен на string, что указывает на бинарную переменную. Статистическая проверка Был выбран t-test, поскольку данные распределены нормально и имеют равные дисперсии (тест Левенне). Результат $p\text{-val}$ примерно 7.62e-70, что значительно меньше порога значимости 0.05. Заключение Отвергаем H_0, поскольку $p\text{-val}$ меньше порога значимости. Это указывает на статистически значимую разницу в средней зарплате между мужчинами и женщинами. Вывод Средняя зарплата мужчин примерно на 0.33 единицы выше, чем у женщин. Это подтверждает гипотезу, что мужчины зарабатывают больше женщин.	Согласуется
Гендерный разрыв сохраняется после учета образования и возраста	Суть исследования H_0: Средние значения переменной lnwage для групп male=0 и male=1 равны H_1: Средние значения переменной lnwage для групп male=0 и male=1 не равны Обработка данных Данные были очищены путем удаления 141 выброса для переменной lnwage, что составляет 8.58 - 11.59. Это было сделано для обеспечения качества данных для анализа. Статистическая проверка Был выбран t-test, поскольку распределение переменной lnwage в обеих группах (male=0 и male=1) является нормальным, а также были равны выборочные дисперсии (тест Левенне). Результат $p\text{-val}$ примерно 7.62e-70, что значительно меньше порога значимости 0.05. Заключение Отвергаем H_0, поскольку $p\text{-val}$ меньше порога значимости. Это означает, что существует статистически значимая разница между средними значениями переменной lnwage для групп male=0 и male=1. Вывод Среднее значение переменной lnwage для группы male=0 (-0.32539857685279827) меньше, чем для группы male=1. Это подтверждает гипотезу о гендерном разрыве в значениях переменной lnwage.	Не согласуется
Жители городов имеют более высокую заработную плату	Суть исследования H_0: Средняя заработная плата жителей городов и других мест одинакова H_1: Средняя заработная плата жителей городов и других мест различна Обработка данных Данные были обработаны путем удаления 141 выброса для переменной 'lnwage', что составляет 8.58 - 11.59. Тип переменной 'urban' был изменен на string (бинарная переменная). Статистическая проверка Был выбран t-test, поскольку распределение данных в обеих группах (группа 0 и группа 1) близко к нормальному, а тест Шапиро-Уилка	Согласуется

	показал $p\text{-val}=0.0000$. Однако, учитывая форму распределения и асимметрию, а также учитывая ЦПМ, небольшие отклонения от нормального распределения допустимы. Кроме того, тест Левенне показал, что выборочные дисперсии равны. Результат $p\text{-val}$ примерно $9.43\text{e-}48$, что значительно меньше порога значимости 0.05. Заключение Отвергаем H_0, поскольку $p\text{-val}$ значительно меньше порога значимости. Существует статистически значимая разница между средними заработными платами жителей городов и других мест. Вывод Средняя заработная плата жителей городов ($\text{urban}=1$) примерно на 0.32 единицы выше, чем средняя заработная плата жителей других мест ($\text{urban}=0$).	
Работа в государственном секторе связана с более низкой заработной платой	Суть исследования H_0: Средняя заработная плата в государственном секторе не отличается от средней заработной платы в частном секторе H_1: Средняя заработная плата в государственном секторе отличается от средней заработной платы в частном секторе Обработка данных Данные были обработаны путем удаления 141 выброса для таргета 'lnwage', что составляет 8.58 - 11.59. После обработки данных не было проведено никаких дополнительных очисток или фильтров. Статистическая проверка Был выбран t-test Welch, поскольку данные имеют нормальное распределение, но выборочные дисперсии не равны (тест Левенне). Распределение данных было проверено с помощью теста Шапиро-Уилка, который показал, что данные имеют нормальное распределение, несмотря на то, что $p\text{-значение}$ было меньше 0.05. Это было обосновано визуальным анализом и небольшим отклонением от нормального распределения. Результат $p\text{-value}$ составил примерно $3.59\text{e-}27$, что значительно меньше порога значимости 0.05. Заключение Отвергаем H_0, поскольку $p\text{-значение}$ меньше порога значимости. Это означает, что существует статистически значимая разница между средними заработными платами в государственном и частном секторах. Вывод Средняя заработная плата в государственном секторе ($\text{public}=0$) составляет примерно 9.90, что больше, чем средняя заработная плата в частном секторе ($\text{public}=1$), которая составляет примерно 9.66. Таким образом, работа в государственном секторе связана с более высокой заработной платой.	Ошибка в интерпретации бинарной переменной, КОРРЕКТНО при инверсии
Использование интернета связано с более высокой заработной платой	Суть исследования H_0: Средняя заработная плата не зависит от использования интернета H_1: Средняя заработная плата зависит от использования интернета Обработка данных Данные были обработаны путем удаления 141 выброса для целевой переменной 'lnwage', что составляет 8.58 - 11.59. Это было сделано для обеспечения качества данных для анализа. Статистическая проверка Был выбран t-test, поскольку данные имеют нормальное распределение, подтвержденное визуальным анализом и тестом Шапиро-Уилка ($p\text{-val}=0.0000$). Однако, учитывая небольшое отклонение от нормального распределения, было принято во внимание, что это допустимо при данном размере выборки. Кроме того, тест Левенне показал, что выборочные дисперсии равны, что также подтверждает выбор t-test. Результат $p\text{-value}$ составляет примерно $7.51\text{e-}43$, что значительно меньше порога значимости 0.05. Заключение Отвергаем H_0, поскольку $p\text{-value}$ меньше порога значимости. Это означает, что существует статистически значимая разница в средней заработной плате между группами с использованием интернета и без него. Вывод Использование интернета связано с более высокой заработной платой. Средняя заработная плата для группы с использованием интернета (1) составляет примерно 9.86, что выше, чем для	Согласуется

	группы без использования интернета (0), которая составляет примерно 9.48. Разница средних составляет примерно -0.36.	
Наличие детей связано с уровнем заработной платы	Суть исследования H0: Нет значимой связи между количеством детей и уровнем заработной платы H1: Существует значимая связь между количеством детей и уровнем заработной платы Обработка данных Данные были очищены от выбросов: 141 выброс был удален для переменной 'lnwage' (8.58 - 11.59), и 884 выброса были удалены для переменной 'children' (0.60 - 6.08). Статистическая проверка Была выбрана линейная регрессия, так как обе переменные ('children' и 'lnwage') являются количественными. Распределение ошибок было проверено с помощью теста Шапиро-Уилка, но результаты не были представлены. Однако, исходя из сводки линейной регрессии, можно сделать вывод, что распределение ошибок не является нормальным (p-value Omnibus: 0.000). Результат p-value для коэффициента 'children' составил примерно 0.142, что больше порога значимости 0.05. Заключение Мы не можем отвергнуть нулевую гипотезу (H0), так как p-value больше порога значимости. Следовательно, нет статистически значимой разницы между количеством детей и уровнем заработной платы. Вывод Количественная связь между наличием детей и уровнем заработной платы не является статистически значимой. Однако, коэффициент линейной регрессии для 'children' составил -0.0218, что указывает на то, что с увеличением количества детей уровень заработной платы может уменьшаться. Но эта связь не является статистически значимой.	Согласуется
У женщин наличие детей связано со снижением заработной платы	Суть исследования H0: Нет значимой связи между количеством детей и логарифмом заработной платы H1: Существует значимая связь между количеством детей и логарифмом заработной платы Обработка данных Данные были обработаны путем удаления выбросов для таргета 'lnwage' (141 выброс) и группировки 'children' (884 выброса). Статистическая проверка Была выбрана линейная регрессия, поскольку обе переменные являются количественными. Распределение ошибок было проверено с помощью теста Шапиро-Уилка, но результаты не были представлены. Однако, исходя из сводки линейной регрессии, можно сделать вывод, что распределение ошибок не является идеально нормальным, но это не является критическим для данного анализа. Результат p-value для коэффициента 'children' составляет примерно 0.142. Сравнивая его с порогом значимости 0,05, можно сделать вывод, что p-value больше порога. Заключение Мы не можем отвергнуть нулевую гипотезу (H0), поскольку p-value больше порога значимости. Следовательно, нет статистически значимой разницы между количеством детей и логарифмом заработной платы. Вывод Исходя из результатов анализа, нельзя сделать вывод о том, что наличие детей напрямую влияет на снижение заработной платы. Однако, коэффициент регрессии для 'children' имеет отрицательное значение (-0,0218), что может указывать на тенденцию к снижению заработной платы с увеличением количества детей. Но эта тенденция не является статистически значимой.	Не согласуется
Отрасль занятости влияет на уровень заработной платы	Суть исследования H0: Средняя заработная плата не зависит от отрасли занятости H1: Средняя заработная плата зависит от отрасли занятости Обработка данных Данные были предварительно обработаны путем удаления 141 выброса, что составило примерно 8,58% - 11,59% от общего количества данных. Это было сделано для обеспечения качества и	Согласуется

	надежности анализа. Статистическая проверка Для проверки гипотезы был выбран критерий Крускала-Уоллиса (Kruskal-Wallis), поскольку тест Левена показал отрицательный результат, указывающий на неомогенность дисперсий. Кроме того, визуальный анализ и тест Шапиро-Уилка показали, что распределение данных в некоторых группах можно считать нормальным, но из-за неомогенности дисперсий было решено использовать непараметрический метод. Результат p-value критерия Крускала-Уоллиса составил примерно $3,10e-60$, что значительно меньше порога значимости 0,05. Заключение Отвергаем H_0, поскольку p-value критерия Крускала-Уоллиса меньше порога значимости. Это означает, что существует статистически значимая разница в средней заработной плате между различными отраслями занятости. Вывод Результаты линейной регрессии показывают, что отрасль занятости имеет значимое влияние на уровень заработной платы. Например, сотрудники в отрасли "НЕФТЕГАЗОВАЯ" имеют более высокую заработную плату, чем в среднем, в то время как сотрудники в отрасли "ОБРАЗОВАНИЕ" имеют более низкую заработную плату. Это подтверждает гипотезу, что отрасль занятости влияет на уровень заработной платы.	
Образование повышает вероятность занятости	Суть исследования H_0: Образование не повышает вероятность занятости H_1: Образование повышает вероятность занятости Обработка данных Очистка не потребовалась, данные были признаны корректными для анализа. Статистическая проверка Была выбрана логистическая регрессия, поскольку мы имеем дело с категориальной переменной "статус" и хотим оценить влияние категориальной переменной "образование" на эту переменную. Распределение данных не было явно проверено на нормальность, но логистическая регрессия не требует нормального распределения данных. Результат p-value для коэффициента "образование" в категории "3" равен примерно 0.031, что меньше порога значимости 0.05. Заключение Мы отвергаем H_0, поскольку p-value меньше порога значимости. Это означает, что существует статистически значимая разница между категориями "образование" и "занятость". Вывод Образование повышает вероятность занятости, особенно в категории "3", где p-value равен примерно 0.031. Это означает, что люди с более высоким уровнем образования имеют большую вероятность быть занятыми.	Согласуется
Использование интернета связано с более высокой вероятностью занятости	Финальный отчет по анализу 1. Суть исследования H_0: Средний lnwage для пользователей с интернетом равен среднему lnwage для пользователей без интернета. H_1: Средний lnwage для пользователей с интернетом больше среднего lnwage для пользователей без интернета. 2. Обработка данных Из таргета 'lnwage' было удалено 141 выбросов в диапазоне от 8.58 до 11.59. Признак 'internet' был преобразован в строковый тип (бинарная переменная). 3. Статистическая проверка Выбран критерий t-test. Выбор обоснован следующим: Распределение: Визуальный анализ и тест Шапиро-Уилкса (p-value=0.0000 для обеих групп) указывают на нормальное распределение признака 'lnwage' в обеих группах ('internet' = 1 и 'internet' = 0). Несмотря на p-value < 0.05, форма распределения (KL-dist 0.009 и 0.027 соответственно) и асимметрия (0.10 и 0.43) позволяют считать распределение близким к нормальному, что подтверждается Центральной Предельной Теоремой при N=3176 и N=554. Гомогенность дисперсий: Выборочные дисперсии признаны равными на основе теста	Согласуется

	Левенна. 4. Результат p-value составляет приблизительно 0.000. Это значение значительно меньше порогового уровня значимости (0.05). 5. Заключение Отвергаем нулевую гипотезу (H_0). Существует статистически значимая разница в среднем значении $\ln wage$ между группами пользователей с интернетом и без него. 6. Вывод Среднее значение $\ln wage$ для пользователей с интернетом (9.856905) больше, чем для пользователей без интернета (9.476118). Разница средних составляет 0.357417.	
--	---	--