

“Система для автоматической проверки статистических гипотез”

Работу выполнил:

Баранов Дмитрий Алексеевич, 9 класс

Руководитель:

Михальченко Эдвард Сергеевич, 1 курс

г. Брянск

Содержание

Введение.....	2
Актуальность.....	2
Цель проекта.....	3
Задачи проекта.....	3
Целевая аудитория.....	4
Показатели назначения проекта.....	4
Анализ существующих решений и методов.....	4
Обзор рынка и существующих аналогов.....	4
Сравнительный анализ аналогов.....	6
Обоснование выбора решения.....	8
Планирование работ и ресурсное обеспечение.....	8
План-график выполнения работ (Календарный план).....	8
Человеческие ресурсы.....	9
Способы привлечения ресурсов.....	9
Реализация проекта и полученные результаты.....	9
Реализация road-map.....	9
Реализация в коде.....	14
Демонстрация рабочего результата.....	15
Методика испытаний.....	17
Перспективы развития проекта.....	18
Заключение.....	18
Список литературы.....	19
Приложение.....	21

Введение

Актуальность

В настоящее время[1] каждый вывод, предлагаемый специалистам и общественности, основывается на убедительных аргументах, а данные, из которых этот вывод вытекает, должны быть получены в ходе четко спланированного исследования, использующего верные методы статистического анализа. В связи с этим использование статистических методов как способ математического подтверждения, является важной частью анализа при написании исследовательской работы.

При некорректном выборе статистического метода исследователь рискует получить как ложноположительные ошибки (отклонить нулевую гипотезу, там где она верна; ошибка I рода) тем самым получить не отражающие реальность выводы, так и ложноотрицательные (подтвердить нулевую гипотезу, там где она неверна; ошибка II рода) тем самым пропустить потенциально важные результаты исследования. Используя некорректный метод, получить результаты отражающие реальность нельзя.

Согласно данным[2] около 16% (в среднем 500 работ в год) отклоняются по причинам: Ошибки в данных, методах и интерпретациях; Манипулирование данными и результатами; Нерепрезентативные результаты. Все эти причины возникают как у опытных исследователей, так и у начинающих, которые часто публикуют свои работы. Современное высшее образование в России ориентировано на формирование у студентов профессиональных компетенций как результата освоения соответствующих программ подготовки. Компетенции представляют собой обобщенные способы действий, опирающиеся на единство теоретической и практической готовности выпускника к осуществлению профессиональной деятельности.

Однако, несмотря на широкие возможности формирования профессиональных компетенций с помощью методов и средств математической статистики, в учебном процессе они задействованы далеко не полной мере[3]. Студенты нередко применяют статистические закономерности неграмотно и формально [4-7]. К наиболее распространенным ошибкам относятся применение параметрических критериев вместо непараметрических без проверки целесообразности и правильности выбора; игнорирование множественности сравнений и повторных измерений; отсутствие

содержательной интерпретации полученных результатов при большом количестве математических выкладок.

Так, студенты при написании работ сталкиваются с **проблемой**:

В условиях относительно низкой компетенции[3] при работе с данными, за счет малой практики или ее отсутствии, а также технически сложным, требующим знания языка программирования (например, python или R) анализом данных, студенты совершают ошибки, упуская проверку важных критериев применения статистических методов. Так отсутствие систематизации приводит к некачественным выводам в итоговых работах.

Цель проекта

Разработать систему, предназначенную для автоматической проверки статистических гипотез, с подбором статистического метода, которая позволит учитывая условия применения, провести проверку и создать поэтапную сводку исследования, для воспроизводимости результата, с подробным описанием использованных методов и интерпретацией полученных результатов.

Задачи проекта

1. Выявить основные проблемы при анализе данных
2. Провести анализ аналогов
3. Разработать road-map работы системы
4. Реализовать MVP систему
5. Провести испытания
6. Оценить эффективность полученного решения

Целевая аудитория

Выпускники/обучающиеся образовательных учреждений использующие статистические методы в проектах/исследованиях.

Показатели назначения проекта

1. Универсальность анализа (возможность проверки всех основных типов статистических гипотез)

2. Доступность (реализация проверок без требования навыков программирования и глубоких знаний математической статистики)
3. Интерфейс (взаимодействие с пользователем на естественном языке)
4. Скорость работы (проверка гипотезы наиболее быстрым способом)
5. Профессиональные навыки (работа с временными рядами, табличными, и другими сложными паттернами в анализе данных. Наличие Feature engineering)

Анализ существующих решений и методов

Существуют различные системы для автоматического создания моделей машинного обучения[4]. В них анализ данных не предполагает явной проверки гипотез. Цель такого анализа - очистить данные и выявить переменные, с наибольшей значимостью для реализации модели. По результатам исследования[5], такие системы могут существенно упростить и ускорить процесс разработки моделей и повысить их точность по сравнению с классификаторами, настроенными вручную, однако на текущий момент времени формируемые модели требуют дальнейшего улучшения. Далее рассмотрим решения, предполагающие проверку статистической гипотезы в явном виде.

Обзор рынка и существующих аналогов

1) Chat GPT и другие LLM - Современные большие языковые модели (LLM), благодаря агентным архитектурам, способны самостоятельно проверять статистические гипотезы[6]. В отличие от ранних моделей, которые предлагали код или алгоритм действий, современные агенты могут взаимодействовать с внешними инструментами для проведения полного цикла анализа. Однако стоит учитывать два критических ограничения:

- 1) **Галлюцинации**, из-за принципа работы таких систем, предсказания токенов модели могут выдавать несуществующие факты или искажать результаты вычислений.
- 2) **Методологические ошибки**, LLM могут игнорировать проверку условий применимости статистических методов. Модель также может ссылаться на условные проверки, не реализованные в коде. Это происходит по причинам оптимизации и сокращения числа токенов, для исключения “лишних” действий.

Взаимодействия происходят на естественном языке, для получения наилучшего ответа требуется написать корректный промпт (запрос) и предоставить данные. Также по описанным ранее причинам стоит проверять полученные результаты.

2) VARIOQUB - Сервис Яндекса для проведения А/Б-экспериментов. Платформа позволяет проверять новые идеи - от улучшений в интерфейсе до алгоритмов поиска и инфраструктурных новшеств, а затем внедрять их для реальных пользователей. Однако возможности сервиса покрывают лишь малую часть в основном бизнес гипотез.

Взаимодействие происходит путем подключения системы к бизнесу и его данными, далее с помощью выбора вариантов (что исследуем? - конверсию/длину сессии и тд.) и сбора данных проводится единственный непараметрический тест, с эвристикой. По итогу сервис является узконаправленным инструментом, исключительно для проведения А/Б тестирования.

3) RapidMiner[7] - это программная многопользовательская платформа, которая представляет собой интегрированную среду для обработки данных в больших информационных массивах, машинного обучения, текстовой аналитики и построения прогностических моделей, а также для решения иных задач Data Mining.

Взаимодействие происходит путем блокового программирования, что облегчает процесс анализа. Стоит отметить, что программа не подбирает метод самостоятельно, а лишь облегчает процесс написания кода.

Сравнительный анализ аналогов

Рассмотрим таблицу аналогов (Таблица 1), оценивать будем по показателям назначения:

№	Название	Универсальность анализа	Доступность	Интерфейс	Скорость работы	Профессиональные навыки	Преимущества	Недостатки	Монетизация
1	ChatGPT и другие LLM	Нет	Частичная	Да	Высокая	Частично зависит от промпта и наличия RAG	Быстрый анализ с низким порогом вход (требуется навыков промпт-инжиниринга)	Частые галлюцинации, требует дополнительной проверки со стороны пользователя. Бесплатные модели не способны	Стоимость подписок 20\$ ≈ 1 500 рублей в месяц

								реализовывать анализ, в основном только текстовые ответы/подсказки.	
2	VARIOQUB от Яндекса	Нет	Полная	Частично	Средняя зависит от минимальных желаемых эффектов гипотезы, и размера сервиса	Отсутствует	Валидация анализа и контроль происходящего. Современный способ проверки бизнес гипотез. Не требует навыков вовсе.	Работает только с А/Б тестами, и требует сбора данных, с помощью сервиса	От 120 000 рублей в месяц Есть ограниченная бесплатная версия
3	RapidMiner	Да	Отсутствует	Нет	Средняя зависит от навыков	Частично требует навыков работы	Ускоряет и облегчает процесс анализа данных	Требует все те же навыков анализа данных, за исключением знания языка программирования	200\$ ≈ 15 000 рублей в месяц Есть ограниченная бесплатная версия

Таблица 1 - Сравнение аналогов

Наше решение будет соответствовать всем показателям назначения.

Возможным ограничением является реализация взаимодействия с пользователем на естественном языке. Решением предлагается использование NLP (Natural Language Processing) или LLM модели.

Обоснование выбора решения

Наше решение предполагает использование автоматизации процесса проверки статистической гипотезы. Так пользователь без требования к знаниям языков программирования и математической статистики может провести анализ, в котором проверка гипотезы происходит путем проверки различных условий, в том числе условий применения статистического метода. За счет использования LLM модели, пользователю необходимо лишь предоставить данные и объяснить гипотезу, после чего, за короткий промежуток времени он получит полноценную сводку об анализе, с интерпретацией всех результатов. Так система автоматизирует проверку гипотез, для разных видов данных.

Планирование работ и ресурсное обеспечение

План-график выполнения работ (Календарный план)

Этап	Сроки	Промежуточный результат
Исследовательский	01.12.2025 - 01.01.2026	Выявлены ключевые ошибки анализа данных, сформированы требования к системе
Проектировочный	02.01 - 01.03	Разработана архитектура и roadmap системы
Технологический	02.03 - 01.05	Реализован MVP системы анализа гипотез
Испытательный	02.06 - 01.07	Проведено тестирование, собрана обратная связь
Аналитический	02.07 - 16.07	Подготовлена документация

Таблица 2 - График выполнения работы

Человеческие ресурсы

Для реализации системы необходимы: Аналитик данных - отвечает за логику и создание проверок условий применения статистических методов; Python-разработчик - отвечает за реализацию систему на языке программирования; Тестировщик - отвечает за корректную работу системы, сбор обратной связи от пользователей.

Способы привлечения ресурсов

Все ресурсы требуемые для реализации систему находятся в свободном доступе.

Реализация проекта и полученные результаты

Реализация road-map

Наиболее распространенными ошибками при практическом анализе данных являются:

1) Отсутствие проверки условия применения статистического критерия.

Например, применение стандартного t - критерия Стьюдента (t -test) предполагает нормальное распределение внутри выборок, или генеральной совокупности, из которой были собраны выборки, гомогенность дисперсий между группами, независимость выборок, отсутствие выбросов в данных, а также рекомендация - достаточный размер выборки. Проверка всех условий может быть упущена или вообще не осуществляться, что ведет к неверному выбору метода.

2) Отсутствие поправок на множественное сравнение. При многократном проведении статистического метода, вероятность ошибки I рода (допустить ложноположительный результат) растет, из за чего требуется корректировать критическое значение альфы, к примеру с помощью поправки Бонферрони.

3) Неверная интерпретация. Некорректное описание полученных результатов или отсутствие причинно следственной связи, в полученных выводах.

Поэтому, необходимо что бы система контролируемо подбирала статистический метод, а также проверяла гипотезу, пополняя список артефактов, выводимых пользователю после завершения исследования.

Важным ограничением, при реализации MVP системы, является проверка на независимость выборок внутри данных. Проверка данного условия требует большей информации про условия сбора данных. На данном этапе, предполагается что данные с которыми работает система - независимые.

Рассмотрим road-map системы (Описание работы для MVP):




Рисунок 1 - Определение переменных исследования

Определение переменных исследования (Рисунок 1)

После запуска системы (с переданными данными, например csv файлом), пользователь пишет запрос на естественном языке. Далее скачанные данные (первые 5 записей) и запрос передается в LLM, с целью определить целевую переменную (таргет) над которой будет проводиться статистический метод (тип данных может быть любой), и групповую переменную, которая делить целевую переменную на выборки. Затем определяются (на основе уникальных) значения групповой переменной, или строго один специальный символ 'ALL' который обозначает, что в анализе требуется рассмотреть все значения групповой переменной. Далее пользователь получает сообщение о выбранных переменных, и если выбор корректный, анализ продолжается. Иначе, с учетом ответа пользователя, и прошлым выбором, переменные переизбираются, до того момента, пока выбор не станет корректным.




Рисунок 2 - Предварительный анализ данных

Предварительный анализ данных (Рисунок 2)

После одобрения пользователем переменных, необходимо провести предобработку.

Сначала определим типы данных (также поменяем бинарные переменные из числа, в строку), исследуемых переменных. Если целевая переменная количественная*, удалим пропуски, если номинативная**, заполним специальным символом 'UNKNOWN'.

После, требуется очистить переменную от выбросов (если переменная количественная) по правилу 1.5 межквартильного размаха.

После предобработки данных, определим задачу исследования. Если группирующая переменная формирует 1 или 2 выборки, то нам необходимо исследовать взаимосвязь между двумя переменными, иначе между несколькими.

*Заполнение пропусков описательными статистиками может сместить распределения, чем исказит результаты при большом числе пропусков. Предсказание пустых значений является ресурсно затратной операцией, требующей переменных в датасете, хорошо описывающих целевую переменную. При большом числе удаленных значений (>50%), пользователь будет уведомлен.

**Так, мы реализуем отдельную категорию, для предотвращения ошибок при использовании статистических методов.




Рисунок 3 - Продвинутая предобработка данных с помощью LLM-агента

Продвинутая предобработка данных (Рисунок 3)

Также, исходя из запроса пользователя, используя LLM-агента, может быть реализована предобработка данных. Используя информацию о данных, и запрос пользователя, определим какие из типов предобработки будут использованы. Также для

выбранных предобработок, получим от LLM список аргументов для реализации, иначе предобработка будет проигнорирована. Далее реализуется одна или несколько предобработок: 1) Группировка и агрегация данных - позволяет агрегировать сгруппированные данные, дополняя итоговый вывод; 2) Смена типа данных у переменной - используя данную предобработку, можно поменять тип данных (во избежание ошибок, в промпт к LLM передаются строгие правила); 3) Реализация интервалов из непрерывной переменной - преобразование переменной в группу (интервал), позволяет изучить общие свойства группы.

Так, система способна редактировать данные, чем убирает ограничение на использование только заранее готовых данных.




Рисунок 4 - Исследование взаимосвязи между двумя переменными

Исследование взаимосвязи между двумя переменными (Рисунок 4)

Далее необходимо выбрать статистический метод, для дальнейшей проверки гипотезы. Если обе переменные количественные, построим линейную регрессию (выбросы удалены ранее) и добавим в артефакты ее сводку, а также корреляции Пирсона и Спирмена.

Если обе переменные номинативные, то проведем проверку гипотезы, с помощью Хи - квадрата Пирсона и Точного критерия Фишера.

Если одна переменная номинативная, а вторая количественная, сначала оценим форму распределения целевой переменной. Если тест Шапиро - Уилка показал, что признак распределен нормально перейдем дальше к анализу, иначе применим метод* Если распределение переменной схоже с нормальным, можем использовать одну из вариаций t - критерия Стьюдента (t-test). Иначе одну из вариаций теста Манна - Уитни. Если распределение переменной схожее с нормальным, и тест Левене доказал гомоскедастичность дисперсий в выборках, можем использовать стандартный t-test, иначе Welch t-test. Если распределение переменной не нормальное, и внутри каждой группы достаточно наблюдений, применим бакетрированный тест Манна - Уитни (случайным образом для каждой выборки реализуем ровно 1000 подвыборок, в каждой из которых рассчитаем среднее значение. После применим на полученных 1000 значений в каждой выборке тест Манна - Уитни), иначе обычный. Также построим логистическую регрессию (выбросы в данных удалены).

Все промежуточные результаты (артефакты) сохраняются. После применения статистического метода, артефакты передаются в LLM, и формируется отчет, которые далее получает пользователь.

*Так как тест Шапиро — Уилка при больших размерах выборки становится чрезмерно чувствительным к малейшим отклонениям, решающее значение в определении формы распределения имеет визуальный анализ. Статистика теста, размер выборки и результаты визуального осмотра (описанные через характеристики распределения) передаются в LLM. Модель выступает в роли эксперта, который на основе совокупности этих данных определяет финальную форму распределения для выбора критерия.

Данный подход математически обоснован: согласно Центральной предельной теореме (ЦПТ), распределение выборочных средних при большом объеме данных стремится к нормальному, что позволяет использовать параметрические тесты даже на сырых данных с умеренными отклонениями. В случаях, когда признак имеет принципиально иную природу (например, равномерное распределение), LLM с высокой точностью идентифицирует его как ненормальное, предотвращая ошибку первого рода визуальный анализ, который вместе с результатом теста, и размером выборки передается в LLM с целью определить форму распределения.




Рисунок 5 - Исследование взаимосвязи между несколькими переменными

Исследование взаимосвязи между несколькими переменными (Рисунок 5)

Также рассмотрим анализ, при задачи исследовать взаимосвязь между несколькими переменными.

Если зависимая переменная количественная, также построим линейную регрессию*

Затем проверив целевую переменную на соответствие нормальному распределению, и гомогенность дисперсий применим ANOVA, иначе непараметрический аналог - критерий Краскала Уоллиса.

Если зависимая переменная номинативная, применим логистическую регрессию.

Также все артефакты сохраняются, и после проверки гипотезы передаются в LLM для составления итогового отчета.

*Не требует проверки на мультиколлинеарность, так как предиктор - номинативная переменная (если группирующая переменная количественная, каждому значению присваивается интервал в котором он принадлежит. Если цель исследование двух количественных переменных, на первом шаге, значения группирующей переменной будет 'ALL')

Реализация в коде

Система реализована на языке программирования Python, с использованием LangGraph. LangGraph - это библиотека для создания сложных приложений с состоянием, построенных на основе графов.

В качестве LLM использовались, llama-3.3 и gemini-flash.

Демонстрация рабочего результата




Рисунок 6 - Пользовательский путь

Пользовательский путь (Рисунок 6) начинается с загрузки данных, и запроса пользователя. Так с помощью датасета Titanic, о кораблекрушении Титаника, содержащим информацию о пассажирах, такую как имя, возраст, пол, и тд. проверим множество гипотез.

На примере одной из гипотез, “Пассажиры первого класса старше пассажиров третьего класса?”, сформулированной в неформальном виде (не указаны явно Н0 (Нулевая гипотеза) и Н1 (альтернативная гипотеза), а также названия переменных) рассмотрим работу системы.

Выбран таргет: age, групповая переменная: class, ее значения: First Third
Вас удовлетворяет выбор?

Рисунок 7 - Вывод выбранных переменных, и ожидание ответа пользователя

Так, система определила (Рисунок 7) целевую переменную как “age” - возраст пассажира. Групповую переменную “pclass” - класс билета, со значениями “First” и “Third” соответственно. Выбранные переменные корректны с точки зрения гипотезы. Поэтому в поле ввода, введем “Да” - выбор удовлетворительный.

... Выбран таргет: age, групповая переменная: pclass, ее значения: 1 3
Вас удовлетворяет выбор? Да

****Сводка исследования****

В рамках данного исследования был проведен анализ данных для сравнения возрастов пассажиров первого и третьего классов. Исследование включало в себя

1. ****Очистка данных****: Были удалены выбросы из данных, в результате чего были установлены границы для возрастов пассажиров: от -6,69 до 64,81. Всего

2. ****Визуальный анализ и проверка нормальности****:

- ****Группа First (Первый класс)****: Распределение возрастов пассажиров первого класса было проверено на нормальность с помощью теста Шапиро-Уилка.
- ****Группа Third (Третий класс)****: Для пассажиров третьего класса тест Шапиро-Уилка показал статистически значимый результат (p-значение = 0,0006)

3. ****Сравнительный анализ****:

- Поскольку распределение возрастов пассажиров третьего класса не было нормальным, для сравнения возрастов пассажиров первого и третьего классов

****Вывод****: Исследование показало, что возрасты пассажиров первого и третьего классов имеют различия. Пассажиры первого класса, как правило, старше п

Рисунок 8 - Сводка об исследовании




Рисунок 9 - Возраст в третьем классе





Рисунок 10 - Возраст в группах

После чего получим сводку об исследовании (Рисунок 8), в которой расписаны этапы:

- 1) Очистка данных, действительно в данных есть выбросы (Рисунок 9).

- 2) Визуальный анализ и проверка нормальности, действительно распределение второго графика ненормальное (Рисунок 10)
- 3) Сравнительный анализ, исходя из-за отсутствия нормального распределения в обеих группах был корректно выбран тест Манна-Уитни

Методика испытаний

Для оценки качества работы системы были проведены тесты различных гипотез. Так, в связи с ограниченными ресурсами для 11 из них измерялись показатели. На основе датасета Iris, включающего характеристики трех видов ирисов, со 150 наблюдениями, проведем контролируемые запуски системы, фиксируя результат гипотезы и время работы.

По результатам тестов, среднее время составило 6-15 (среднее значение и верхняя граница 95% доверительного интервала) секунд, данное время зависит от типа гипотезы и количества условий применения статистического метода. Результаты системы согласуются с исследованиям[8] Роналда Эйлера Фишера, ирисов в 1936 году.

Исходя из полученных результатов, составим таблицу (Таблица 3) показателей назначения проекта:

Таблица 3 - показатели назначения итоговой системы:

Универсальность анализа	Доступность	Интерфейс	Скорость работы	Необходимость профессиональных навыков
Да	Да	Да	Да	Нет

Система выполняет почти все показатели назначения проекта. На момент создания MVP система не способна осуществлять Feature engineering и работать с временными рядами. При попытке реализации таких гипотез, система начнет проверку схожей гипотезы.

Однако для наиболее распространенных среди исследователей задач MVP система работоспособна, она выполняет на базовом уровне поставленную цель, и отвечает большинству показателей назначения.

Перспективы развития проекта

- 1) Создание полноценной системы, которая сможет реализовывать подготовку данных для дальнейшей систематизированной проверки гипотез, путем внедрения полноценного LLM агента.
- 2) Создание приложения/сайта/бота для взаимодействия.
- 3) Тестирование с участием исследователей.
- 4) Монетизация проекта.

Заключение

В течение работы над проектом был проведен анализ наиболее частых проблем при исследованиях у студентов, на основе которых был представлен основной функционал системы, а именно проверка гипотезы путем систематизированного подбора статистического метода. Был рассмотрен roadmap MVP системы, последующе реализованный на языке программирования Python, с использованием LangGraf.

Проверка работоспособности подтвердила качество полученного результата.

Цель проекта была достигнута, с помощью системы можно провести проверку гипотезы, а также получить полноценную воспроизводимую сводку исследования с интерпретацией полученных результатов.

При использовании системы целевой аудиторией, студенты могут быстро проверять гипотезы, взаимодействуя на естественном языке. С учетом всех особенностей данных система подберет статистический метод, а также предоставит полноценную сводку исследования. По данной сводке можно воспроизвести анализ, или интерпретировать результаты для области исследования.

Список литературы

- 1) Румянцев П.О., Саенко У.В., Румянцева У.В. Статистические методы анализа в клинической практике. Часть I. Одномерный статистический анализ. Проблемы Эндокринологии. 2009;55(5):48-55. <https://doi.org/10.14341/probl200955548-55>
- 2) The Retraction Watch Database [Internet]. New York: The Center for Scientific Integrity. 2018. ISSN: 2692-4579. [Cited (applicable date)]. Available from: <http://retractiondatabase.org/>.
- 3) Торопова С. И. Методы математической статистики как средство формирования профессиональных компетенций студентов экологов // Образование и наука. 2018. Т. 20. № 3. С. 53–82. DOI: 10.17853/1994-5639-2018-3-53-82
- 4) Вараксин А. Н. Статистический анализ биологической и медицинской информации: проблемы и решения // Международный журнал медицинской практики. 2006. № 2. С. 35–39.
- 5) Леонов В. П. Общие проблемы применения статистики в биомедицине или Что разумнее: ДДПП или ДППД? // Биометрика: электронный журнал [Электрон. ресурс]. 2015. Режим доступа: <http://www.biometrica.tomsk.ru/problem.htm>
- 6) Lang T., Altman D. Basic statistical reporting for articles published in clinical medical journals: the SAMPL Guidelines // Science Editors' Handbook, European Association of Science Editors. Smart P, Maisonneuve H., Polderman A. (eds). 2013. Available from: <http://www.equator-network.org/2013/03/20/basicstatistical-reporting-for-articles-published-in-biomedical-journals-the-statisticalanalyses-and-methods-in-the-published-literature-or-the-sampl-guidelines/>
- 7) Yusof Z. M., Abdullah S., Yahaya S. S. S., Othman A. R. A Robust Alternative to the t – Test // Modern Applied Science. 2012. № 5 (6). P. 27–33. Available from: <http://citeseerx.ist.psu.edu/viewdoc/download?doi=10.1.1.1014.7331&rep=rep1&type=pdf>
- 8) Болодурина И. П. и др. Автоматизированное машинное обучение: обзор возможностей современных платформ анализа данных //Системная инженерия и информационные технологии. – 2021. – Т. 3. – №. 1 (5). – С. 50-57.
- 9) Мосин К. К., Ковалевский В. Э., Жукова Н. А. Использование методов автоматизированного машинного обучения для классификации дорожно-транспортных происшествий //Интеллектуальные технологии на транспорте. – 2023. – №. 2 (34). – С. 15-26.

- 10) Ашихмин Евгений Георгиевич, Левченко Валерий Витальевич, Селеткова Гюзель Ильясовна Опыт применения больших языковых моделей для анализа количественных социологических данных // Вестник ГГУ. 2024. №11. URL: <https://cyberleninka.ru/article/n/opyt-primeneniya-bolshih-yazykovyh-modeley-dlya-analiza-kolichestvennyh-sotsiologicheskikh-dannyh>
- 11) Платформа RapidMiner для анализа данных. – Текст : электронный // Высшая школа бизнеса : [сайт]. – 07.05.2020. – URL: <https://hsbi.hse.ru/articles/platforma-rapidminer-dlya-analiza-dannykh/> (дата обращения: 16.02.2026).
- 12) Fisher R. A. The use of multiple measurements in taxonomic problems //Annals of eugenics. – 1936. – Т. 7. – №. 2. – С. 179-188.
- 13) Образовательные материалы Института биоинформатики. – Текст : электронный // Stepik : образовательная платформа. – URL: <https://stepik.org/org/bioinf> (дата обращения: 18.02.2026).
- 14) Документация LangGraph. – Текст : электронный // LangChain : [сайт]. – URL: <https://docs.langchain.com> (дата обращения: 14.02.2026).
- 15) Иванова Марина Михайловна, Волков Павел Юрьевич, Бобров Андрей Дмитриевич АНАЛИЗ ТИПИЧНЫХ ОШИБОК ВЫПУСКНЫХ КВАЛИФИКАЦИОННЫХ РАБОТ И ПУТИ ИХ ПРЕДОТВРАЩЕНИЯ // Проблемы современного педагогического образования. 2022. №75-3. URL: <https://cyberleninka.ru/article/n/analiz-tipichnyh-oshibok-vypusknyh-kvalifikatsionnyh-rabot-i-puti-ih-predotvrascheniya>
- 16) Основы статистики : [онлайн-курс] / Институт биоинформатики. – Текст : электронный // Stepik : [сайт]. – URL: <https://stepik.org/course/76/syllabus> (дата обращения: 16.02.2026).
- 17) Основы статистики II : [онлайн-курс] / Институт биоинформатики. – Текст : электронный // Stepik : [сайт]. – URL: <https://stepik.org/course/524/syllabus> (дата обращения: 16.02.2026).
- 18) Основы статистики III : [онлайн-курс] / Институт биоинформатики. – Текст : электронный // Stepik : [сайт]. – URL: <https://stepik.org/course/2152/syllabus> (дата обращения: 16.02.2026).

Приложение

Приложение 1

Код реализованный на языке программирования Python выложен на публичный репозиторий github:

https://github.com/dmibar/Sirius_BC26/tree/main/Code

Система использует архитектуру графа, созданные функции поэтапно, в зависимости от выполнения условия выполняются, изменяя состояние графа. Каждый этап пополняет состояние “*artefacts*” на основе которого по итогу создается сводка исследования. LLM выступает в роли переводчика между системой и пользователем. Так система получается систематизированным и быстрым способом проверить гипотезу. По результатам сводки, исследователь сможет проверить результаты и интерпретировать их для своей области исследования.

Приложение 2

Исследование отзывов с публикаций статей:

https://github.com/dmibar/Sirius_BC26/tree/main/research

Для начала была скачана база данных Retraction Watch - блог, который сообщает об отзывах научных статей и связанных с ними темах. Далее с помощью документации, были отобраны следующие причины для отзыва статьи: Ошибки в анализе, методах, и интерпретации; Манипуляция данными и результатами; Воспроизводимость полученных результатов.

По результатам анализа были получены следующие выводы, в среднем в год более чем 500 (~16%) научных работ отзывается по причинам описанным выше. Так как ошибки при статистической проверки гипотез актуальны для исследователей публиковавшихся в международные журналы, то студенты свойственны допускать не меньшее их количество.

Приложение 3

Граф системы на языке разметки Mermaid:




Рисунок 11 - Граф реализованной системы реализованной на Python

Приложение 4




Рисунок 12 - График распределения среднего времени работы и матрица ошибок при тестовых 11 проверок гипотез на датасете Iris

Так как время работы системы сильно зависит от гипотезы и входных данных, выбрано среднее значения для усреднения времени. Медиана покажет лишь время работы наиболее быстрых гипотез, не учитывая сложные гипотезы требующие проверку множества условий применения.

Стоит отметить что используя разные LLM модели, и изменяя системный промпт, можно получать более или менее релевантные ответы.